

UNIVERSIDADE FEDERAL DO ABC

ENGENHARIA DE INFORMAÇÃO

SISTEMAS INTELIGENTES

**Aplicação de Redes Neurais Artificiais na
Locomoção Virtual da Plataforma Bioloid
ROBOTIS Premium Através de Cinemática
Inversa**

Alunos:

Gilmar Correia Jeronimo

RA:11014515

Sergio Polimante Souto

RA:21063712

Docente:

Dr. Ricardo Suyama

16 de dezembro de 2016

Santo André - SP

Sumário

1	Introdução	3
2	Contextualização e Resultados	5
2.1	Redes Neurais Artificiais	5
2.2	Cinemática	6
2.2.1	Cinemática Direta	6
2.2.2	Cinemática Inversa	7
2.3	Locomoção Humanoide	7
2.3.1	MLP para cada motor	9
2.3.1.1	Aproximação do CoM simulado	9
2.3.1.2	Aproximação do CoM desejado	11
2.3.1.2.1	Teste para melhor caso de treino da rede MLP	12
2.3.2	MLP para todos motores	14
2.3.2.1	Aproximação do CoM simulado	14
2.3.2.2	Aproximação do CoM desejado	15
2.3.2.2.1	Teste para melhor caso de treino da rede MLP	15
2.3.3	MLP analisando os instantes de tempo anteriores	18
2.3.3.1	Aproximação do CoM simulado	18
3	Conclusão	19
4	Trabalhos Futuros	20

Resumo

Esse relatório apresenta o estudo, implementação e alguns dos resultados obtidos após a aplicação de Redes Neurais Artificiais (RNAs) na resolução da cinemática inversa da locomoção de um robô humanoide com 10 graus de liberdade. Para análise desse problema se requer conhecimento na área para o estudo da cinemática do robô, sendo dificultado pela quantidade de servos presentes. Além disso, diferentemente de um robô não-móvel, o humanoide precisa controlar muitos graus de liberdade (DOFs) e permanecer em equilíbrio. Portanto, o objetivo foi tentar obter apenas uma melhoria no algoritmo de locomoção já existente, como diminuição de ruídos, aumento da estabilidade e da velocidade do caminhar do robô. A partir de um estudo realizado anteriormente na plataforma, foi obtido uma solução na locomoção, a proposta para esse relatório é otimizar a sua locomoção, tornando o movimento mais suave e natural, aproximando de uma função desejada. Para esse estudo foi utilizado o *software Virtual Robot Experimentation Platform* (V-REP) como ambiente de simulação virtual, o programa ECLIPSE para executar os comandos do robô e mandar a informação necessária para a plataforma de simulação, e MATLAB para o desenvolvimento e implementação das RNAs.

1 Introdução

A construção de um robô ajuda os estudantes a lidarem com as imperfeições dos dispositivos do mundo real, bem como proporcionar o retorno imediato do sucesso ou falha de suas ideias. Como a robótica envolve uma grande e variada gama de áreas do conhecimento, os estudantes aprendem que muitas perspectivas podem ser úteis para solucionar um problema, sendo motivados a aprender a língua de cada uma dessas áreas para quebrar as barreiras da interdisciplinaridade. Desta forma, o conhecimento é adquirido através de diversas áreas e começarão a ver um sistema como um todo e não mais como subsistemas isolados.

A robótica é uma área jovem da ciência e interdisciplinar. A solução de problemas em robótica geralmente envolvem diversas áreas, como Engenharia Elétrica, Engenharia Mecânica, Ciências da Computação, Matemática, entre outras. A inspiração na natureza como forma de tentar propor soluções para alguns problemas da tecnologia tem sido explorada e é conhecida como tecnologia bioinspirada que busca, através dos avanços feitos em Biologia e Neurociência, respostas para problemas em áreas como Computação e Robótica. As RNAs são um exemplo de Computação Bioinspirada, que a partir dos avanços feitos em Neurociência sobre o funcionamento do cérebro e das redes neurais, serviram de inspiração para a criação de um novo paradigma de programação e a implementação de algoritmos que possam se capaz de solucionar problemas de maneira adequada.

Os humanoides são os principais representantes do estado da arte no campo da robótica. A sua principal característica é a capacidade de parecer e agir muitas vezes como humanos, além de um excelente alvo para pesquisas em diversas áreas. Com relação a locomoção, os robôs com pernas são a melhor opção para ambientes acidentados ou projetados para seres humanos, não necessitando de muito espaço para se locomover. Entretanto, exige a utilização de um controle inteligente para o caminhar de forma estável.

Muitos conceitos físicos são empregados durante a movimentação de um ser humano, e o mesmo princípio acontece com os humanoides, porém de forma mais limitada. Toda a estrutura do corpo de um humanoide é estabilizado pelo pé durante a locomoção, sendo necessário que se localize no espaço e controle a sua massa para conseguir se locomover.

Em robótica, cinemática é o estudo do movimento do robô com um referencial ex-

terno cartesiano fixo, não levando em consideração a origem das forças que atuam no sistema. Os modelos cinemáticos são conhecidos como diretos e inversos. O modelo de cinemática direta possibilita determinar a posição e direção de algum ponto no espaço em função das configurações de seus atuadores, enquanto que o modelo cinemático inverso, permite que a partir de uma determinada posição e direção da garra, seja possível obter a configuração de seus atuadores. ^[1]

Para a sua locomoção acontecer com eficiência muitos projetos utilizam algoritmos inteligentes, em especial, RNAs para a determinação, a partir de exemplos, da cinemática direta e inversa do robô, como mostrado no trabalho de Lope et al. ^[2](2003).

A plataforma Bioloid ROBOTIS Premium é uma plataforma educacional de um robô humanoide com 18 DOFs, possibilitando a estudo por sua interface do RoboPlus, ou através da implementação de códigos em Java, Python, C e C++ para os servos motores da *Dynamixel*.

Foi considerado um modelo simplificado para a cinemática direta e inversa da plataforma Bioloid ROBOTIS Premium. A cinemática direta possibilita saber a posição do centro de massa do robô em um referencial fixo cartesiano em função da configuração dos 10 atuadores das pernas, enquanto que a cinemática inversa possibilita determinar a configuração dos 10 atuadores em função de um determinado centro de massa. O objetivo é atuar com a plataforma no ambiente de simulação V-REP a adquirir dados para comparar as respostas dadas pelas RNAs.

2 Contextualização e Resultados

Para o desenvolvimento do projeto, alguns conceitos abordados como RNA e cinemática direta e inversa precisaram ser estudadas, para ter uma noção sobre a resolução do problema da locomoção do humanoide. Esta seção abordará alguns conceitos teóricos sobre estes tópicos.

2.1 Redes Neurais Artificiais

Uma RNA é um modelo computacional baseado nas estruturas funcionais biológica das redes neurais humanas. A RNA é composta por um conjunto de unidade de processamento que efetuam operações simples, um modelo livre aproximado de um neurônio biológico, no qual a capacidade de processamento está armazenada na intensidade das conexões entre os neurônios.

Uma RNA pode ser formada por um ou diversos neurônios, assim como o neurônio biológico, a RNA apresenta estruturas para tornar possível o processamento de informação. Suas sinapses representam a informação de entrada do neurônio, os dendritos os pesos que cada uma dessas informações têm para o neurônio, o corpo somático representa a somatória das informações com seus devidos pesos, além da função de ativação. Toda essa informação processada passa para o axônio gerando o resultado.

A resposta obtida pelo neurônio pode ser comparado a uma resposta desejada, gerando um sinal de erro. Esse sinal de erro atualiza, junto com um coeficiente de aprendizado, os pesos das informações recebidas.

Existem diversos tipos de RNAs e o utilizado neste projeto é do tipo *feed forward network*, a Figura 1 ilustra a estrutura dessa rede neural, que é composta por uma camada de neurônios de entrada, uma camada de saída, e opcionalmente, camadas intermediárias, conhecidas como *hidden layers*.

O treinamento de uma rede é feito a partir de um conjunto de dados de treinamento, compostos por dados de entrada que levam a um determinado conjunto de dados de saída. O treino consiste em encontrar os pesos multiplicadores das conexões entre neurônios, e quando obtidos com sucesso, a RNA é capaz de aproximar funções não lineares ou encontrar padrões em conjunto de dados.

Portanto, como é conhecido que o problema de locomoção de robôs móveis é de caráter não linear, as RNAs são uma boa ferramenta para a resolução da cinemática




Figura 1: Estrutura de uma RNA do tipo *feed forward network*

direta e inversa da modelagem de locomoção do robô humanoide.

2.2 Cinemática

Cinemática é o estudo na locomoção de um corpo sem a consideração de forças externas atuando no sistema ou momentos que possam causar movimentação. Muitos estudos de cinemática envolvem desde braços robóticos até robôs humanoides, permitindo a movimentação das juntas para um determinado ponto no espaço cartesiano, sendo chamado de cinemática direta, ou a partir de um ponto no espaço se obter a melhor configuração de juntas, sendo chamado de cinemática inversa, ilustrado na Figura 2.

Problemas de natureza não linear, como o da movimentação das juntas do robô humanoide, acabam sendo um problema complexo de resolver. Portanto, a cinemática, tanto direta quanto inversa, é um tipo de transformação linear, que leva de um espaço de ângulos das juntas, para algum ponto no espaço cartesiano, e vice-versa. ^[3]

A cinemática pode incluir não somente o ângulo das juntas, como também a velocidade, aceleração e posição das mesmas. Tais informações permitem um maior conhecimento da complexidade do problema a ser resolvido. ^[4]

2.2.1 Cinemática Direta

A cinemática direta calcula a posição e orientação de um ponto do robô, como as extremidades das mãos, pés ou do Centro de Massa (CoM) em função das juntas dos motores. Alguns métodos como o de Denavit-Hartenberg usam quatro parâmetros para descrever a cinemática do robô, no qual i representa o número da junta, entre eles:

- Tamanho do link entre as juntas (a_{i-1});




Figura 2: Representação de cinemática direta e inversa ^[3].

- Inclinação entre as juntas (α_{i-1});
- Deslocamento entre conexões das juntas (d_i);
- Ângulo da junta (θ_i);

Tendo estes parâmetros, é possível criar uma matriz de transformação que dado os ângulos dos motores, resulta em uma posição no espaço cartesiano. Além disso, com os estes parâmetros obtidos, é possível através de conversões geométricas obter os elementos rotacionais de cada junta. ^[3]


2.2.2 Cinemática Inversa

A cinemática inversa consiste numa transformação contrária, no qual dado um ponto no espaço é possível obter as configurações das juntas para aquele ponto. Para esse problema existe dois tipos de aproximação, a geométrica e a algébrica.


A aproximação geométrica leva em conta os ângulos entre as juntas e o tamanho dos braços, após uma série de conversões é possível obter os ângulos em termos da posição do ponto desejado e dos ângulos formados por outras juntas. A aproximação algébrica utiliza a matriz de transformação, determinada na direta para determinar a solução dos ângulos de cada junta. ^[3]

2.3 Locomoção Humanoide


A partir do modelo em 3D da plataforma e do estudo realizado em Jeronimo^[5](2016) foi possível adquirir dados da locomoção do humanoide, analisando a dinâmica do CoM e




(a)



(b)



(c)



(d)

Figura 3: Em (a) Ângulo dos Motores em Função do Tempo. (b) Posição do CoM no Eixo X em Função do Tempo. (c) Posição do CoM no Eixo Y em Função do Tempo. (d) Posição do CoM no Eixo Z em Função do Tempo.

dos motores, vendo como tais fatores influenciam na locomoção. Os dados são mostrados nas Figuras 3(a), 3(b), 3(c) e 3(d).

Os dados dos motores foram analisados para uma única passada completa, que dura 13,7 ciclos, sendo que cada atualização no motor dura 0,05 ciclos, portanto em uma passada completa há 274 posições dos motores.

Para realização dos testes com a RNA, foi coletado dados de diversos ciclos de caminhada do humanoide, variando os seus ângulos, inserindo ruídos aleatórios no algoritmo original, para obter dados diversos para o treino da rede.

Após adquirir os dados necessários e analisar a dinâmica do CoM, percebeu-se uma pequena oscilação no eixo x e z na ordem de $\Delta x = 0,03$ e $\Delta z = 0,025$, enquanto que o




Figura 4: Em (a) Posição do CoM Desejado no Eixo X em Função do Tempo. (b) Posição do CoM Desejado no Eixo Y em Função do Tempo. (c) Posição do CoM Desejado no Eixo Z em Função do Tempo.

eixo y varia com um $\Delta y = 0,275$. Observando esse comportamento, foi criada uma função desejada para a locomoção do CoM, no qual o eixo x deveria avançar positivamente, o eixo y oscilar como uma função de onda e o eixo z ficar em uma posição constante. Tal equação do CoM pode ser representado na Equação 1.

$$CoM(t) = \begin{cases} x(t) = 0,79955316 + (0,00008t) \\ y(t) = \left[0,035\pi \cos\left(\frac{t}{1369} - \frac{t-319}{165}\right) - 1,2 \right] \\ z(t) = 0,29080275 \end{cases} \quad (1)$$

Nesta função de onda, é definido o período T de oscilação como o tempo definido de uma passada 13,7 ciclos ou 1369 instantes de tempo. Enquanto que a amplitude da onda é o resultado de $\frac{0,035}{2}$, que apresenta uma amplitude de 1,75 e seu $\lambda = 165$, ou seja, seu comprimento de onda. No final é subtraído 1,2 para normalizar a curva de acordo com o CoM da passada de exemplo. Tais funções tem o seguinte caráter, mostrado na Figura 4.

2.3.1 MLP para cada motor

A primeira RNA criada para testar a aproximação foi realizada com uma *Multi-Layer Perceptron* (MLP) para cada motor, no qual a entrada é o valor no motor e a saída é a posição do CoM do robô.

2.3.1.1 Aproximação do CoM simulado

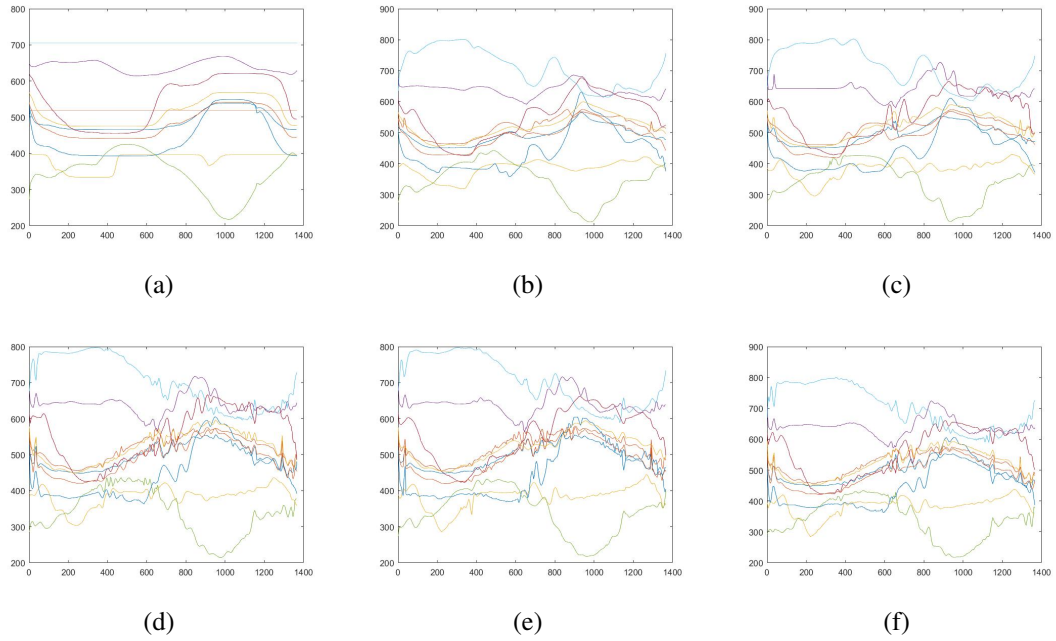



Figura 5: Resultado dos Ângulos da MLP: (a) 1 Neurônio. (b) 5 Neurônios. (c) 10 Neurônios. (d) 50 Neurônios. (e) 100 Neurônios. (f) 200 Neurônios.


A partir desses parâmetros gerados foram criadas MLPs para cada motor, fazendo a aproximação da função desejada. No primeiro momento foram dados 3931 exemplos de motores para posição do CoM, tentando aproximar assim da função de entrada do próprio robô, neste momento não foi analisado a posição do CoM desejado.

As respostas obtidas pela MLP foram bem próximas da Figura 3(a), conforme verificado na Figura 6, apresentando alguns ruídos ao aumentar o número de neurônios da rede. Com esse resultado das redes, concluiu-se que a rede estava apta ao teste com o CoM desejado definido pela Equação 1.

Para realizar o teste com o CoM desejado foram utilizados o mesmo número de neurônios do teste anterior com o CoM obtido da simulação. Neste caso, dois tipos de redes foram treinadas, as redes para obtenção da cinemática inversa de cada motor, sendo uma rede para cada motor, e a rede para a obtenção da cinemática direta, utilizando os dados dos motores e gerando um CoM. Com os resultados obtidos da rede é possível comparar a resposta dos novos ângulos gerados pela rede de cinemática inversa, a resposta desejada e a resposta dada pela rede da cinemática direta.




(a)




(b)

Figura 6: Comparação Entre a Aproximação do CoM com Dados do Simulador: (a) Resposta dos Motores com a Função Antiga. (b) MLP de 200 Neurônios.



(a)




(b)


Figura 7: Comparação Entre a Aproximação do CoM Desejado no Eixo Y, em Azul a Função Desejada, em Laranja a Função Obtida pela MLP da Cinemática Direta e em Amarelo a Resposta Real do Simulador: (a) 1 Neurônio. (b) 3 Neurônios.

2.3.1.2 Aproximação do CoM desejado


Para rede da cinemática direta foram usados vinte neurônios na camada intermediária da MLP. Após os testes com o CoM desejado percebeu que aumentar a quantidade de neurônios deixa a rede muito flexível, o que fazia o humanoide cair. A Figura 7 mostra a comparação entre as resposta desejada, em azul, a resposta da cinemática direta, em laranja, e a resposta real obtida com o simulador, em amarelo.




(a)



(b)



(c)



(d)

Figura 8: Teste da Melhor Opção de Treino para a Rede MLP de Acordo com o CoM Desejado. (a) Resposta Obtida com Treino Somente em Y. (b) Resposta Obtida com Treino em X e Y, Respectivamente. (c) Resposta Obtida com Treino em Y e Z, Respectivamente. (d) Resposta Obtida com Treino em X, Y e Z, Respectivamente.

Como conclusão, percebeu que a rede MLP de um neurônio para cada motor não atende de maneira satisfatória o modelo do robô, já que os motores estão livres e não possuem influência um sobre o outro, o que não acontece realmente. Além disso, ao aumentar o número de neurônios, os motores passam a ter picos de resposta, ultrapassando do limite de locomoção e inclinação das juntas.

2.3.1.2.1 Teste para melhor caso de treino da rede MLP

Mesmo com poucos neurônios, a MLP individual de 3 neurônios na camada inter-

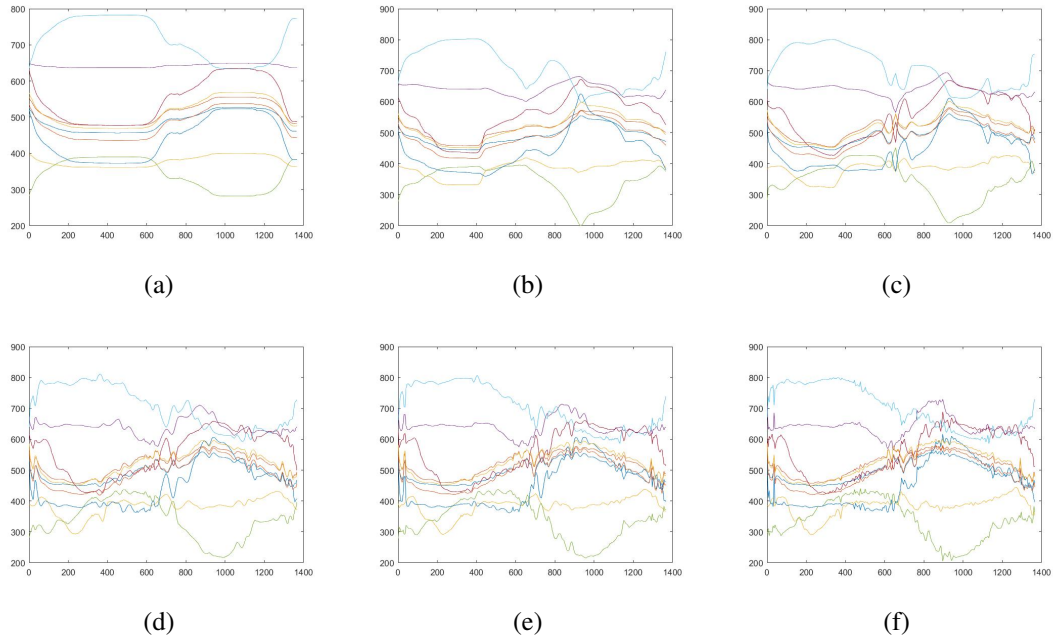


Figura 9: Resultado dos Ângulos da MLP Única: (a) 1 Neurônio. (b) 5 Neurônios. (c) 10 Neurônios. (d) 50 Neurônios. (e) 100 Neurônios. (f) 200 Neurônios.

mediária fez uma boa aproximação do obtido pelo simulador. A partir disso, e sabendo o número de neurônios ideal para se trabalhar com o CoM desejado é possível analisar quais dados de treino interferem mais no resultado da aproximação da locomoção. Para isso, foram feitos teste treinando com dados de x , y , z , xy , xz , yz e xyz .

Em ambos os casos é possível analisar a relevância de cada um dos dados de treino para a rede. Treinando o resultado do CoM somente com dados do eixo x , a melhor tendência para o robô é ele permanecer com as juntas constantes, ou seja, não alterar sua inclinação. Com os dados do eixo y , na Figura 8(a), a resposta obtida foi concisa e permaneceu com o robô em equilíbrio. Somente com os dados do eixo z acontece o mesmo efeito que os dados somente em x , o robô tende a ficar parado, sendo essa sua melhor aproximação.

Com os dados do plano xy , na Figura 8(b), obteve-se uma aproximação com pouco erro do desejado para ambos os eixos, sendo que a resposta real de x variou um $\Delta x = Estado_{final} - Estado_{inicial} = 0,832029 - 0,798472 = 0,033557$, uma proporção um pouco maior que a original do robô. Com os dados do plano xz , o robô fica parado pois a melhor aproximação da rede é ficar com os motores constantes. Com os dados




Figura 10: Comparação Entre a Aproximação do CoM com Dados do Simulador: (a) Resposta dos Motores com a Função do Simulador. (b) MLP Única de 200 Neurônios.

do plano yz foi possível aproximar somente com os resultados para um neurônio na camada intermediária, mais neurônios ocasionava a queda do robô. A função criada pela aproximação em yz, na Figura 8(c), foi muito próxima da função desejada em y, sendo essa a melhor aproximação do eixo y, com menor erro, da Figura 8.

Por fim, foram testados os dados de xyz, na Figura 8(d), porém somente a aproximação com um neurônio obteve êxito. Analisando a movimentação nos eixos e os dados obtidos da simulação, x teve um mínimo de ganho com $\Delta x = 0,823277 - 0,813385 = 0,009892$, em y obteve um boa aproximação e em z apresentou a melhor aproximação do que as outras mostradas nos testes.

2.3.2 MLP para todos motores

Outro teste feito foi montar uma rede MLP com dez entradas, ou seja, com as entradas de todos os motores e com três saídas, resultando no CoM. Para este teste foram criadas duas redes MLP, uma para obtenção da resposta da cinemática direta e outra para a obtenção da resposta da cinemática inversa.

2.3.2.1 Aproximação do CoM simulado

Para a realização de teste com o CoM simulado, se fez a aproximação da resposta aumentando o número de neurônios nas camada intermediarias de 1, 5, 10, 50, 100 e

200.

Como observado na Figura 9, a rede MLP única apresenta mais estabilidade e menos ruído que a rede MLP para cada motor. Portanto, ao aumentar a quantidade de neurônios presente na rede, melhor é a aproximação do CoM simulado pois por ser uma rede única pode verificar a influência de cada motor na movimentação do CoM, e não como somente como um caso isolado.

A Figura 10 compara a aproximação gerada por uma rede MLP única de 200 neurônios. O treinamento da rede de 200 neurônios na camada intermediária custa muito computacionalmente, demorando cerca de uma hora e quarenta minutos para gerar resposta compatível com a aproximação.

Com os testes realizados, é possível aplicar o treinamento da rede para obter os motores a partir do CoM desejado, que será detalhado na próxima seção.

2.3.2.2 Aproximação do CoM desejado


O mesmo teste realizado com a MLP para cada motor, foi realizado neste caso, analisando se a resposta obtida pela rede é compatível com a resposta dada pelo simulador.

Para obter a resposta do possível CoM, a combinação de motores gerados pela rede da cinemática inversa foi colocada e simulada na rede da cinemática direta, treinada com vinte neurônios. Com isso, é possível obter a linha laranja da Figura 11, enquanto a linha azul representa a função do CoM desejado e a amarela a resposta do simulador, assim como no primeiro teste.


As resposta obtidas pelo simulador em ambos os casos de 1 a 15 neurônios apresentam um curva similar, aumentando o ruído da função conforme o número de neurônios aumenta. A rede é constante com um baixo número de neurônios na camada intermediária representando bem o modelo da plataforma Bioloid ROBOTIS Premium no V-REP.

O próximo teste foi verificar se a ordem dos parâmetros do CoM interferem no sistema. Foi analisado então a influência no treino com os dados de x, y, z, xy, xz, yz e xyz para este tipo de rede.


2.3.2.2.1 Teste para melhor caso de treino da rede MLP




(a)



(b)



(c)




(d)


Figura 11: Comparação Entre a Aproximação do CoM Desejado no Eixo Y, em Azul a Função Desejada, em Laranja a Função Obtida pela MLP da Cinemática Direta e em Amarelo a Resposta Real do Simulador: (a) 1 Neurônio. (b) 5 Neurônios. (c) 10 Neurônios. (d) 15 Neurônios.

Neste teste, foi utilizado a rede de cinemática inversa com sete neurônios na camada intermediária. Treinando a rede somente com dados do eixo x, a melhor aproximação é o robô ficar com suas juntas imóveis durante todo o período da passada. Treinado a rede somente com dados do eixo y, na Figura 12(a), foi obtido uma combinação de motores que permitia o equilíbrio do robô e sua locomoção. Analisando os dados plotados pelo simulador, o $\Delta x = 0,850266 - 0,798523 = 0,051743$ sendo esta a maior variação de locomoção em x. Treinando a rede em z a melhor aproximação seria não se locomover, não sendo interessante para o problema.


Treinando com os dados no plano xy, na Figura 12(b), o Δx não houve grande




(a)



(b)



(c)



(d)

Figura 12: Teste da Melhor Opção de Treino para a Rede MLP Única de Acordo com o CoM Desejado. (a) Resposta Obtida com Treino Somente em Y. (b) Resposta Obtida com Treino em X e Y, Respectivamente. (c) Resposta Obtida com Treino em Y e Z, Respectivamente. (d) Resposta Obtida com Treino em X, Y e Z, Respectivamente.

avanço, sendo seu valor $\Delta x = 0,8294119 - 0,7985295 = 0,0308824$, enquanto que sua aproximação em y ficou próxima da desejada. Treinando com os dados no plano xz a melhor aproximação é quando os motores ficam parados. Treinando com os dados no plano yz, na Figura 12(c), foi obtido um $\Delta x = 0,8356304 - 0,8031382 = 0,0324922$.

Finalmente, treinando com os dados de xyz, na Figura 12(d), o $\Delta x = 0,8718387 - 0,8779765 = -0,0061378$ e as aproximações de y e z estão bem próximas da função desejada, com mínimo de erro.

Com isso conclui-se que a rede cinemática inversa única com sete neurônios com aproximação somente com dados do eixo y é a melhor aproximação que otimiza a lo-




Figura 13: Aproximação do CoM Simulado com 10 Neurônios.

comoção do humanoide, aumentando a passada e ajustando o deslocamento no eixo y.

2.3.3 MLP analisando os instantes de tempo anteriores

Outro teste realizado, foi criar um rede com entradas de instante de tempo anteriores, colocando assim as derivadas no treinamento da RNA. Então, como entradas obtém, as dez primeiras como os motores em um instante de tempo t, as dez segundas como os motores em um instante de tempo t-1 e as dez terceiras como os motores em um instante de tempo t-2.

2.3.3.1 Aproximação do CoM simulado

Para o primeiro teste foi aproximado do CoM simulado, assim como nos outros testes, verificando se os motores são aproximados de maneira similar as das outras redes, porém não se obteve resultado conclusivo para os motores, como mostrado na Figura 13.

O tempo de processamento fica inviável analisando a quantidade de neurônios que deveria ser utilizado para a aproximação da rede.

3 Conclusão

O presente trabalho foi um estudo para analisar o melhor método de otimizar a locomoção do humanoide aproximando de uma função desejada.

Foram testadas RNAs MLP para cada motor, para o sistema como um todo e para instantes de tempo anteriores, criando uma rede para cinemática direta e outra para cinemática inversa. Com esses resultados foi possível testar e analisar o conjunto de dados para aplicação na locomoção do humanoide.

Com os testes realizados a melhor solução, foi a MLP única para todos os motores com os dados de treino somente em y, deixando os eixos x e z livres, obtendo uma variação em Δx maior do que o simulado.

Com isso, o objetivo para este trabalho foi concluído, otimizando a locomoção do humanoide além de deixar um movimento mais suave possível.

Alguns teste adicionais, concluíram que a função desejada era um parâmetro correto para treino, pois ao oscilar a amplitude do passo a RNA apresenta resultados compatíveis com o modelo do robô.

Ao longo do projeto foi obtido diversas ideias que serão comentadas nos planos futuros do projeto.

4 Trabalhos Futuros

Alguns dos experimentos inicialmente planejados foram desenvolvidos neste trabalho, entretanto uma gama de outros testes não puderam ser desenvolvido por falta de tempo e recurso. Durante a execução dos testes, várias outras ideias surgiram que também não puderam ser implementadas. Essa seção descreverá alguns dos possíveis estudos e implementações a serem feitos como continuação deste trabalho.

Maior amostragem de dados para treino

A quantidade de dado de treino utilizada neste trabalho foi suficiente para chegar a algumas conclusões, mas seria ideal se houvesse um volume de dados de ordem maior. Entretanto, isso eleva o custo computacional inviabilizando a implementação nos computadores que foram utilizados neste trabalho.

Pelo fato das RNA utilizadas aproximarem funções de \mathbb{R}_{10} para \mathbb{R}_3 , existem muitos parâmetros a serem treinados na RNA o que reforça a necessidade de um conjunto de dados de treino grande e representativo.

Para diversificar os dados de treino, foi inserido ruído nas funções dos motores ao executar o algoritmo do robô para caminhar, entretanto, o ideal é que o ruído fosse ainda maior e aplicado de diferentes formas no algoritmo. Dados para treino gerados a partir do robô executando outros algoritmos também são importantes e não puderam ter sido gerados.

Melhor definição do problema do deslocamento em $x(t)$

Nos experimentos, o robô desloca-se na direção $x(t)$, logo, aumentar o valor de $x(t)$ com o tempo é fundamental para uma locomoção eficiente. Para isso, foi modelado a função ideal $x(t)$ como uma reta, com amplitude nos instantes de tempo inicial e final do período aproximadamente iguais à função simulada, de forma que o coeficiente angular de $x(t)$ fosse gradualmente aumentando, logo, aumentando a velocidade do robô na direção $x(t)$.

Entretanto, ao desprezar a forma da função simulada, fazendo uma aproximação simples para uma reta gerou resultados inconclusivos. Uma possível implementação seria encontrar a função analítica que descreve $x(t)$ e modificá-la de forma a aumentar a amplitude no início e fim do período, porém fazer isso mantendo o erro entre a função ideal e simulada o menor possível.

Referências

- 1 JUNIOR, F. E. F. et al. Estudo e implementação de redes neurais e algoritmos genéticos para resolução de cinemática inversa de um manipulador robótico com 5 graus de liberdade. Campinas, SP, 2014.
- 2 LOPE, J. D. et al. Inverse kinematics for humanoid robots using artificial neural networks. In: SPRINGER. *International Conference on Computer Aided Systems Theory*. [S.l.], 2003. p. 448–459.
- 3 KUCUK, S.; BINGUL, Z. *Robot kinematics: forward and inverse kinematics*. [S.l.]: INTECH Open Access Publisher, 2006.
- 4 CROWDER, R. M. *Automation and Robotics: Robot Kinematics*. jan 1998. Acessado em 14 de Dezembro de 2016. Disponível em <<http://www.southampton.ac.uk/~rmc1/robotics/arkinematics.htm>>.
- 5 JERONIMO, G. C. Estudo da locomoção dos humanoides com validação real na plataforma robotis. *PDPD*, p. 1–125, 2016.